

## Лабораторная работа № 2

### Тема: Предобработка данных.

Для выполнения данной лабораторной работы можно использовать любой найденный датасет с пропусками в разных столбцах, а если пропусков нет, то необходимо их сгенерировать (пропуски должны быть в разных столбцах, чтобы поработать с ними различными способами). Также в датасете помимо числовых данных должны присутствовать текстовые, для дальнейшей замены их на числа. Если ваш датасет из первой лабораторной соответствует этим критериям, то можете использовать его.

Вот пара ссылок на датасеты с пропусками:

<https://www.kaggle.com/datasets/ander289386/cars-germany>

<https://www.kaggle.com/datasets/arnabchaki/fitness-trackers-products-ecommerce>

Пример предобработки данных можно посмотреть в файле *Titanic\_missing\_data.html* в папке *Examples*.

### Задание:

1. Выявите пропуски данных несколькими способами (визуальный, расчетный...)

*При удалении (замене) пропусков необходимо рассуждать: можно ли удалить данный параметр и чем целесообразно заменять пропуски данных в конкретных параметрах, руководствуясь описанием параметров датасета и предметной областью.*

2. Исклучите строки, столбцы с большим количеством пропусков. Выведите количество удаленных строк.
3. Произведите замену оставшихся пропусков на логически обоснованные значения различными способами: замена на среднее/медиану, замена на значение по методу л-ближайших соседей.
4. Постройте гистограмму распределения исходного датасета до и после обработки пропусков. Сделайте выводы как обработка данных повлияла на их распределение.
5. Проверьте датасет на наличие дубликатов и при необходимости удалите их.
6. Проверьте датасет на наличие выбросов. Порассуждайте представляют ли эти выбросы интерес для дальнейшего изучения (быть может это аномально большое количество откликов на вакансию, можно проанализировать что это за вакансии и почему такой спрос, и т.д.). Удалите найденные аномальные записи из основного датасета.
7. Приведите все параметры к числовому виду (кодирование текстовых данных). Примените методы кодирования: Label Encoding и One-Hot Encoding.
8. Проведите нормализацию данных.
9. Сохраните обработанный датасет в отдельный csv-файл.

### Вопросы:

1. Перечислите различные способы обнаружения пропущенных данных.
2. Приведите пример категориальных данных.
3. Какими способами можно закодировать категориальные данные?
4. Как работает One-Hot Encoding?
5. Какие существуют способы нормализации?
6. Какие еще встречаются ошибки данных помимо пропусков и выбросов?