

Лабораторная работа № 4

Тема: Бинарная классификация

1. Выберите любой доступный на просторах интернета набор данных (dataset) подходящий для **бинарной классификации**. Хорошо подходят датасеты по различным болезням, где надо определить есть болезнь/нет болезни или выдача кредитов – выдавать/не выдавать, или отток клиентов мобильных операторов – уйдут/не уйдут и т.д.

Найти подходящие датасеты можно здесь:

<https://www.kaggle.com/datasets?search=binary+classification>

Требования к набору данных:

- минимум пять признаков, описывающих объект (можно больше);
- минимум 100 объектов для обучающего набора (можно больше);
- по набору можно оценить вероятность какого-то бинарного исхода (например, выживет/не выживет, здоровый/больной, женат/неженат, кредит выдавать/не выдавать и т.п.)

2. Проанализируйте исходные данные. **Проведите предобработку**, при необходимости заполните пропуски или удалите не важную информацию. **Категориальные признаки замените на числовые**.

3. Выделите из данных вектор меток Y и матрицу признаков X .

4. Разделите набор данных на обучающую и тестовую выборки.

5. На обучающей выборке **обучите модели дерева решений и k-ближайших соседей**, рассчитайте точность моделей.

6. Подберите наилучшие параметры моделей (например, глубину для дерева решений, количество соседей для алгоритма knn). Можно построить график ошибок и увидеть при каких параметрах ошибки наименьшие, или использовать другие способы.

7. Рассчитайте матрицу ошибок (confusion matrix) для каждой модели.

8. Выберите лучшую модель.

9*. Визуализируйте полученную модель дерева решений (при визуализации желательно уменьшить глубину дерева, что бы рисунок был читаемым, или сохранить в отдельный файл). Обратите внимание на изменение коэффициента *gini* в узлах дерева. Что он обозначает?

Вопросы:

1. Сформулируйте задачу классификации?
2. Что означает обучение с учителем?
3. Зачем разделять обучающую выборку?
4. Что означает переобученная модель? Как с этим бороться?
5. Что означает обобщающая способность моделей машинного обучения?
6. Объясните значения в матрице ошибок, как она рассчитывается?
7. Что показывают метрики accuracy, precision и recall?
8. Объясните принцип работы дерева решений. Как в дереве решений выбирается по какому признаку будет произведено деление в узле?