

Лабораторная работа № 5

Тема: Линейные классификаторы.

В качестве данных для обучения используйте датасет с большим количеством параметров, подходящий для бинарной классификации. Например, Breast Cancer Wisconsin или другой.

1. Сделайте предобработку данных, не забывайте про нормализацию, для моделей линейной классификации это важно.
2. Обучите **модель логистической регрессии LogisticRegression ()**.
 - Рассчитайте точность на обучающих и тестовых данных
 - Измените в модели параметр регуляризации C, по умолчанию C=1, пересчитайте с C= 100 и C= 0,01. Вновь выведите точность на обучающем и тестовом наборах. Сделайте выводы.
 - Выведите значения коэффициентов модели
 - Примените L2-регуляризацию, по умолчанию используется L1-регуляризация
 - Выведите значения коэффициентов модели при L2-регуляризации, сделайте выводы как работают L1 и L2-регуляризации.
 - Рассчитайте метрики качества (*accuracy, precision, recall*) и матрицу ошибок для наилучшей на ваш взгляд модели.
3. Обучите **модель метода опорных векторов SVC()**.
 - Рассчитайте точность на обучающих и тестовых данных.
 - В методе опорных векторов для регуляризации в основном используют параметры C и гамма. При помощи метода GridSearchCV найдите наилучшую комбинацию этих параметров:

```
from sklearn.model_selection import GridSearchCV
SVC_params = {"C": [0.1, 1, 10], "gamma": [0.2, 0.6, 1]}
SVC_grid = GridSearchCV(model_SVC, SVC_params, cv=5, n_jobs=-1)
SVC_grid.best_score_, SVC_grid.best_params_
```
 - Выведите точность этой модели на обучающих и тестовых данных, сделайте выводы
 - Рассчитайте метрики качества (*accuracy, precision, recall*) и матрицу ошибок для наилучшей модели метода опорных векторов.
4. В этом же файле (блокноте) обучите на этом же датасете модели дерева решений и K-ближайших соседей. Выведите их точность на обучающих и тестовых данных.
5. Постройте в одних осях четыре ROC-кривые для 4-х обученных моделей (логистической регрессии, метода опорных векторов, дерева решений и K-ближайших соседей). Сделайте вывод какая модель лучше делает прогноз на ваших данных.

```
from sklearn.metrics import RocCurveDisplay
ax = plt.gca()
rfc_disp = RocCurveDisplay.from_estimator(model_SVC, X_test, y_test, ax=ax)
svc_disp = RocCurveDisplay.from_estimator(model_DT, X_test, y_test, ax=ax)
```

... ..
... ..

```
plt.show()
```

где `model_` - это ваши ранее обученные 4 модели

Вопросы

1. В чем суть линейных классификаторов? Какие методы относятся к линейным классификаторам?
2. Что такое регуляризация?
3. Объясните назначение L1 и L2-регуляризации?
4. Объясните влияние параметров C и гамма на регуляризацию модели?
5. Какой метод помогает подобрать лучшую комбинацию параметров?
6. Что такое специфичность и чувствительность модели? Проанализируйте какая из этих метрик наиболее важна для ваших данных?
7. Для чего используют ROC-кривую? Что означает AUC в ROC-кривой?