Белорусский Государственный Технологический Университет
Кафедра Информационных Систем и Технологий

Отчёт

Сравнительный анализ методов текстовой стеганографии

Замена пробелов и невидимые символы Unicode

Тема курсового проекта

Велотрекер с построением маршрутов

Выполнил студент 4 курса 6 группы
Филипюк Илья Андреевич

Минск 2026

1 Цель работы

Сравнить метод замены пробелов и метод невидимых символов Unicode по заметности, влиянию на исходный текст, стойкости к обнаружению и сохранности после преобразования формата. Практическая часть должна определить, какой метод уместен для HTML и PDF, как на результат влияют язык контейнера и длина сообщения, а также какие ограничения делают скрытый канал ненадёжным.

Главный результат эксперимента: zero-width метод визуально точнее и обладает большей ёмкостью, но оба метода легко обнаруживаются по кодовым точкам. Замена пробелов оказалась особенно чувствительной к PDF и нормализации пробелов. Невидимые символы лучше пережили выбранный PDF-конвейер, однако длинные сообщения в PDF восстановить не удалось.

2 Условие задания

Необходимо провести теоретический и практический анализ двух способов текстовой стеганографии: Space Steganography и Zero-Width Characters Steganography. Сравнение выполняется для английских и русских контейнеров, коротких, средних и длинных сообщений, а результаты представляются в HTML и PDF.

Фактор	Значения
Метод	Замена U+0020 на U+00A0; вставка U+200B и U+200C
Язык контейнера	Английский и русский
Длина сообщения	8, 32 и 96 байт
Формат	HTML и PDF
Проверки	Прямое извлечение, HTML-текст, PDF-текст, нормализация пробелов, удаление Cf

3 Теоретические основы

3.1 Стеганография заменой пробелов

В выбранной реализации бит 0 задаётся обычным пробелом U+0020, а бит 1 — неразрывным пробелом U+00A0. Перед полезной нагрузкой записывается

32-битная длина сообщения. Кодирование не меняет слова и знаки препинания, но изменяет свойства переноса строк: U+00A0 запрещает обычный разрыв между соседними словами. Поэтому метод может стать заметным при выравнивании текста или узкой колонке.

Классические whitespace-схемы также используют пробелы и табуляции в конце строк. Например, программа SNOW скрывает данные в последовательностях конечных пробелов и табуляций. В этой работе использована замена внутренних пробелов, потому что она применима к сплошному HTML-тексту и позволяет непосредственно сравнить Unicode-маркеры обоих методов.

3.2 Стеганография невидимыми символами

Второй метод вставляет после видимых символов U+200B ZERO WIDTH SPACE для бита 0 и U+200C ZERO WIDTH NON-JOINER для бита 1. U+200B не имеет собственной ширины, но обозначает возможность переноса; U+200C управляет соединением и лигатурами. Для латиницы и кириллицы при обычном наборе они чаще всего не дают видимого глифа, однако остаются в строке как отдельные кодовые точки категории Cf.

Нулевая ширина не гарантирует одинаковый результат во всех движках. Алгоритм переноса, шрифт, очистка Unicode и копирование через промежуточный формат могут удалить символы или изменить их порядок. В письменностях, где ZWNJ имеет языковое значение, произвольная вставка может менять форму слова, поэтому такой алфавит нельзя считать универсальным.

3.3 Сравнение принципов

Характеристика	Замена пробелов	Невидимые символы
Позиции для встраивания	Только обычные пробелы	Почти каждый видимый символ
Визуальный риск	Изменение переноса строк	Обычно отсутствует; возможны особенности лигатур и переноса
Простой детектор	Подсчёт U+00A0	Поиск U+200B и U+200C или категории Cf
Типичная очистка	Унификация всех пробелов	Удаление форматирующих символов
Основное преимущество	Простая реализация и понятная модель	Высокая ёмкость и точное визуальное совпадение

4 Методика эксперимента

Для каждого языка сформирован нейтральный текст о велотрекере: 8466 видимых символов в английском контейнере и 8691 в русском. В каждый контейнер последовательно встраивались сообщения из 8, 32 и 96 байт. С учётом 32-битного заголовка требовалось 96, 288 и 800 бит соответственно. Всего выполнено 12 основных случаев; каждый сохранён в HTML и PDF.

1. Сформировать битовую строку из длины и сообщения.
2. Встроить биты выбранным методом без изменения видимых букв.
3. Проверить прямое извлечение и извлечение из HTML-текста.
4. Создать PDF, извлечь из него текст и повторить декодирование.
5. Применить нормализацию пробелов и удаление символов Unicode категории Cf.
6. Отрисовать чистый и стеганографический PDF и подсчитать долю изменившихся пикселей.

Для PDF использованы ReportLab, шрифт DejaVu Sans и извлечение через pdfplumber. Пиксельное сравнение выполнено после рендеринга Poppler при 110 dpi. Поэтому результаты характеризуют конкретный воспроизводимый конвейер, а не все существующие редакторы и просмотрщики.

5 Результаты эксперимента

Метрика	Замена пробелов	Невидимые символы
Прямое извлечение	100 %	100 %
HTML исходник	100 %	100 %
HTML видимый текст	100 %	100 %
PDF извлечение	0 %	67 %
После нормализации пробелов	0 %	100 %
После удаления Cf	100 %	0 %
Ёмкость на 1000 видимых символов	150.6 бита	1000.0 бита
Изменённых пикселей на миллион	91555.2	0.0

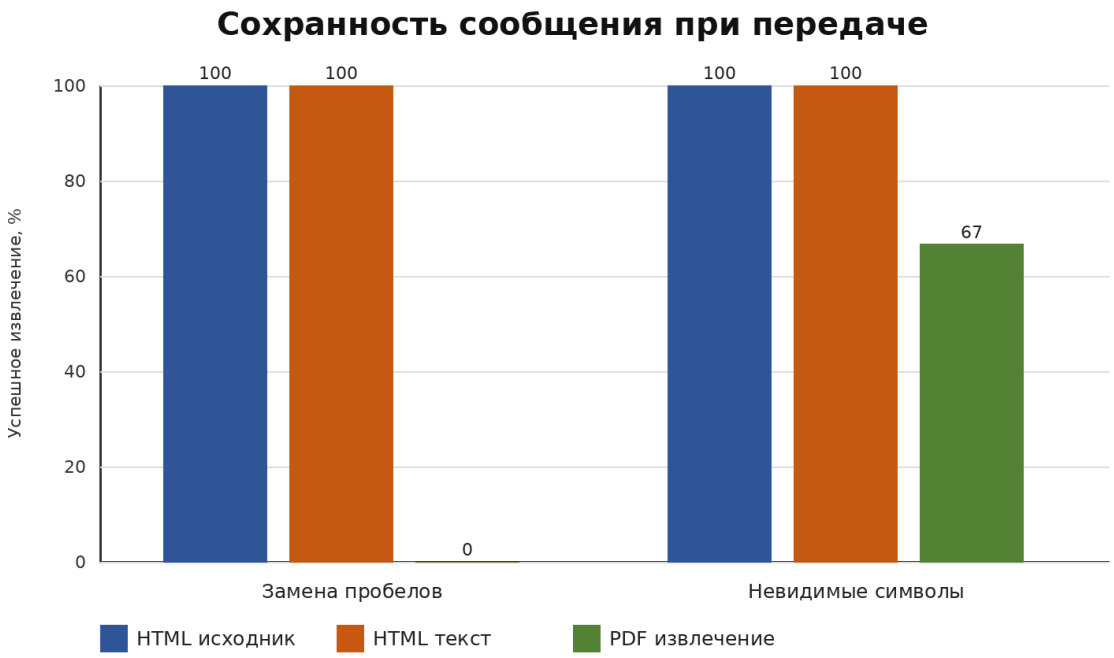


Рисунок 1 — Сохранность сообщения при передаче через HTML и PDF

Оба метода полностью сохранились в HTML. При извлечении текста из PDF метод пробелов дал 0 %, потому что различие U+0020 и U+00A0 не сохранилось в доступной декодеру форме. Невидимые символы дали 67 %: короткие и средние сообщения восстановились для обоих языков, а длинные — нет.

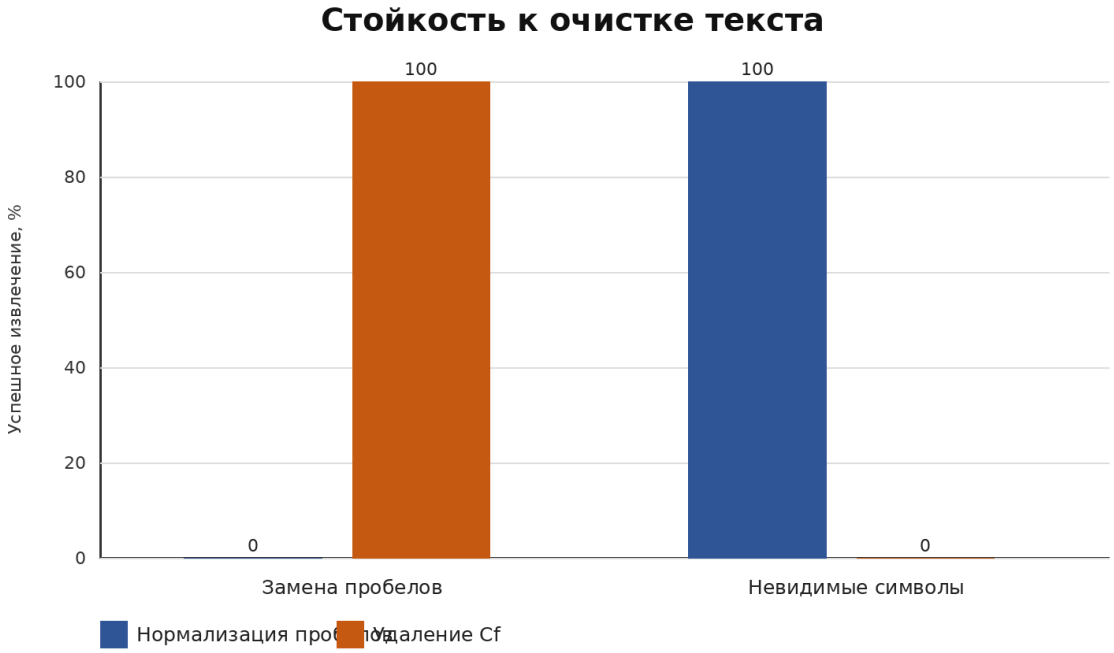


Рисунок 2 — Стойкость к двум видам очистки текста

Атаки оказались взаимно дополнительными. Нормализация пробелов полностью уничтожила канал замены пробелов, но не затронула U+200B и U+200C. Удаление символов категории Cf уничтожило zero-width канал, сохранив U+00A0. Следовательно, ни один метод не выдерживает целевую очистку, если защитник знает тип алфавита.



Рисунок 3 — Доступная ёмкость контейнера

Zero-width вариант предоставил в среднем 1000 позиций на 1000 видимых символов. Замена пробелов дала 150,6 позиции, то есть примерно в 6,6 раза меньше. Различие между английским и русским контейнерами связано с частотой пробелов: 168,3 позиции на 1000 видимых символов для английского текста и 132,9 для русского.

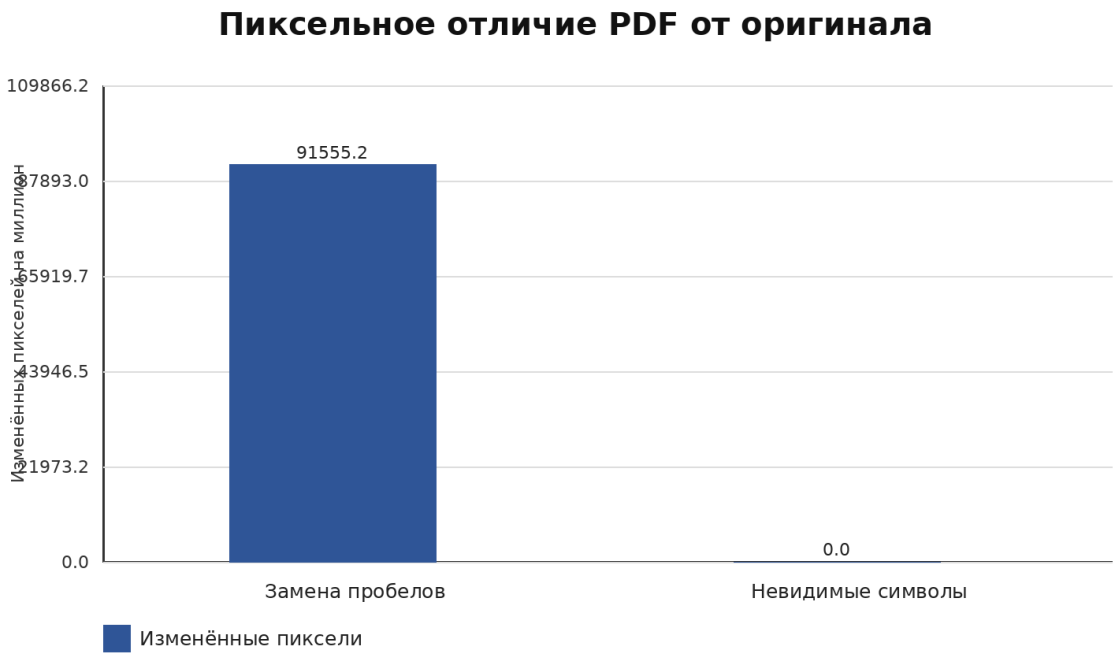


Рисунок 4 — Пиксельное отличие PDF от чистого контейнера

Zero-width PDF совпал с чистым контейнером на уровне пикселей во всех 6 случаях. Для метода пробелов среднее отличие составило 91 555 пикселей на миллион, то есть около 9,16 %. Причина — запрет переносов в позициях U+00A0 и последующее перераспределение строк. На русском тексте влияние было сильнее из-за иного распределения длины слов и меньшей частоты пробелов.

5.1 Влияние длины сообщения

Метод	Сообщение	PDF	Пикселей на млн	Заполнение
Замена пробелов	Короткое, 8 байт	0 %	48834.0	7.5 %
Замена пробелов	Среднее, 32 байта	0 %	102116.4	22.6 %
Замена пробелов	Длинное, 96 байт	0 %	123715.2	62.7 %
Невидимые символы	Короткое, 8 байт	100 %	0.0	1.1 %
Невидимые символы	Среднее, 32 байта	100 %	0.0	3.4 %
Невидимые символы	Длинное, 96 байт	0 %	0.0	9.3 %

Для zero-width метода рост длины не изменил изображение, но снизил надёжность PDF: при 96 байтах результат составил 0 %. У замены пробелов визуальное отклонение возрастало вместе с числом U+00A0. Это означает, что

длинная полезная нагрузка одновременно повышает заметность и увеличивает вероятность потери.

5.2 Влияние языка

Язык не повлиял на прямое извлечение и результаты атак очистки. Различия проявились в доступной ёмкости и компоновке PDF. Английский контейнер содержал больше пробелов относительно числа видимых символов, поэтому метод пробелов имел большую ёмкость. Zero-width метод использовал позиции после букв и знаков и потому дал одинаковое нормированное значение для обоих языков.

6 Анализ заметности, качества и безопасности

6.1 Степень заметности

Для человека zero-width метод оказался незаметнее: рендер PDF не изменился. Замена пробелов заметна косвенно по переносу строк, особенно при средней и длинной нагрузке. Для автоматического анализатора оба метода очевидны. Проверка на U+00A0, U+200B и U+200C пометила 100 % стеганографических контейнеров.

6.2 Качество исходного текста

Семантика слов не менялась ни в одном методе. Однако качество документа включает и вёрстку. U+00A0 объединяет соседние слова в неразрывные фрагменты, поэтому строка может стать неравномерной. U+200B и U+200C в выбранных латинских и кириллических текстах не дали видимых отличий, но способны влиять на перенос и лигатуры в других движках и письменностях.

6.3 Безопасность

Оба метода обеспечивают только сокрытие факта передачи и не заменяют шифрование. Частота нестандартных кодовых точек, позиционная регулярность и длина скрытой последовательности дают простые признаки обнаружения. Целевой фильтр удаляет канал за один проход. Без шифрования извлечённая нагрузка читается, а без кода аутентификации её можно незаметно изменить.

Сравнительный анализ методов текстовой стеганографии

Угроза	Замена пробелов	Невидимые символы	Мера снижения риска
Unicode-сканер	Легко находит U+00A0	Легко находит U+200B/U+200C	Шифровать нагрузку; уменьшать и рандомизировать число маркеров
Нормализация	Канал уничтожается	Обычно сохраняется	Выбирать профиль под известный канал передачи
Удаление Cf	Сохраняется	Канал уничтожается	Резервное кодирование или иной алфавит
PDF-конвертация	В опыте 0 %	В опыте 67 %	Тестировать конкретный редактор и извлекатель
Повреждение одного бита	Сдвиг или ошибка длины	Сдвиг или ошибка длины	Синхромаркеры, CRC и помехоустойчивый код

7 Сильные и слабые стороны

Метод	Сильные стороны	Слабые стороны
Замена пробелов	Простая реализация; понятное извлечение; сохраняется при удалении Cf	Низкая ёмкость; заметное влияние на перенос; полная потеря после нормализации и в выбранном PDF-конвейере
Невидимые символы	Высокая ёмкость; нулевое пиксельное отличие; устойчивость к нормализации пробелов	Легко обнаружить и удалить; длинное сообщение потерялось в PDF; возможное влияние на лигатуры и языковую норму

8 Области применения и рекомендации

Сценарий	Предпочтительный вариант	Обоснование
Контролируемый HTML-канал	Невидимые символы	Оба метода дали 100 %, но zero-width имеет большую ёмкость и не изменил изображение
Документ с жёсткой вёрсткой	Невидимые символы после проверки	U+00A0 меняет перенос; zero-width нужно проверить в конкретном движке
Канал с удалением Cf	Замена пробелов	Zero-width данные будут удалены; пробельный метод сохранится, если не нормализуются пробелы
Канал с нормализацией пробелов	Невидимые символы	Метод пробелов в опыте потерял сообщение полностью
Неизвестные редакторы и PDF	Не использовать без предварительного теста	Результат зависит от конвертера; ни один метод не дал полной надёжности

Сценарий	Предпочтительный вариант	Обоснование
Конфиденциальная передача	Шифрование плюс проверенный канал	Стеганография без криптографии не защищает содержание

Практический выбор следует начинать не с визуальной незаметности, а с известного пути документа. Если канал контролируется и остаётся HTML, zero-width метод предпочтительнее. Если текст проходит нормализаторы, мессенджеры, офисные редакторы или PDF-конвертеры, необходимо выполнить сквозной тест на том же программном стеке. Для критичных данных скрытый канал следует считать дополнительным слоем, а не основной защитой.

9 Направления развития

- Шифровать и сжимать полезную нагрузку перед встраиванием, чтобы убрать читаемую структуру и сократить число маркеров.
- Добавить CRC, код исправления ошибок и периодические синхромаркеры для восстановления после частичной потери символов.
- Выбирать позиции псевдослучайно по ключу, а не заполнять контейнер с начала, чтобы снизить регулярность распределения.
- Создать профили совместимости для браузеров, офисных редакторов, мессенджеров и PDF-конвертеров.
- Использовать адаптивный алфавит с учётом языка: не вставлять ZWNJ там, где он меняет соединение букв, и избегать U+00A0 около вероятных переносов.
- Оценивать заметность автоматическим детектором и визуальным рендерингом одновременно; одна метрика не отражает весь риск.

10 Выводы

Практический эксперимент подтвердил, что zero-width метод эффективнее по ёмкости и визуальному качеству. Он предоставил примерно в 6,6 раза больше позиций и не изменил пиксельный рендер PDF. В HTML оба метода обеспечили полное восстановление сообщений любой исследованной длины.

Преимущество zero-width метода не означает универсальной стойкости. В PDF восстановились только 4 из 6 сообщений, а удаление символов Cf уничтожило канал полностью. Метод замены пробелов не пережил ни нормализацию пробелов, ни извлечение из PDF и заметно изменил перенос строк.

Для контролируемого HTML-канала рекомендуется zero-width вариант с шифрованием, проверкой целостности и умеренной нагрузкой. Метод пробелов оправдан только там, где гарантированно сохраняются типы пробелов и не выполняется повторная вёрстка. В неизвестном канале требуется предварительное сквозное тестирование; для конфиденциальных данных оба метода должны дополнять, а не заменять криптографическую защиту.

11 Использованные источники

1. Unicode Consortium. The Unicode Standard, Version 18.0, Chapter 23 Special Areas and Format Characters. Сведения о U+00A0, U+200B и U+200C. https://www.unicode.org/versions/Unicode18.0.0/core-spec/chapter-23/

2. WHATWG. HTML Living Standard. Правила обработки текста и пробельных символов в HTML. https://html.spec.whatwg.org/

3. Kwan M. SNOW whitespace steganography program, version 1.1. Описание скрытия данных конечными пробелами и табуляциями. https://github.com/mattkwan-zz/snow/blob/master/snow.1

4. Исходный код и результаты эксперимента в каталоге Lab_4: experiment.py и output/results/experiment_results.csv. Дата выполнения 11.11.2026.

Приложение А Состав материалов

Скрипт experiment.py воспроизводит встраивание, извлечение, атаки, создание HTML/PDF и расчёт метрик. Таблица experiment_results.csv содержит 12 строк с параметрами каждого случая. Каталоги output/samples/html и output/samples/pdf содержат контейнеры, а output/charts — четыре графика, включённые в отчёт.